

# Projet de Certification IA

## Système d'Orientation et de Prévention du Chômage Longue Durée

**Candidat :** Franck Beugnet — *Promo ATOS Atlas IA (Parcours 2 : Pros IT)*

*Conception, industrialisation et audit d'un produit Data de bout en bout*

**Stack :** Python 3.12 · Scikit-Learn · LightGBM · FastAPI · Streamlit · MLflow · Prometheus · Docker

## Plan de la Soutenance (30 minutes cadencées)

1. Cadrage Métier, Éthique & Objectifs (AI Act) [00:00 - 05:00 | 5 min]
2. Audit, Qualité & Pipeline End-to-End [05:00 - 10:00 | 5 min]
3. Modélisation, 4 Scénarios & Explicabilité (SHAP) [10:00 - 17:00 | 7 min]
4. Architecture Cible, Flux SI & Déploiement API [17:00 - 22:00 | 5 min]
5. Supervision MLOps, CI/CD & Dérive (Drift) [22:00 - 27:00 | 5 min]
6. Bilan Économique, Perspectives & Démonstration [27:00 - 30:00 | 3 min]


# 1. Cadrage Métier & Objectifs

## Le Constat Métier

- **Contexte** : Flux massif d'utilisateurs au 1<sup>er</sup> entretien.
- **Objectif** : Aiguiller tôt vers l'accompagnement renforcé.
- **Solution IA** : Modèle multimodal (tabulaire + synthèse textuelle).
- **Cible (3 classes)** :
  - 0 (Rapide < 6m) : 37%
  - 1 (Moyen 6-12m) : 44%
  - 2 (Risque long > 12m) : 18% (*critique*)

### Doctrine "No Mercy" sur le Risque :

Priorité absolue au **Rappel** sur la classe 2 plutôt qu'à l'Accuracy. Prédire 0 pour un vrai 2 est une perte de chance humaine et financière inacceptable.



## Cadre Réglementaire, RGPD & Responsabilité Juridique

L'usage de l'IA dans l'orientation professionnelle impose un cadre de conformité strict :

### 1. AI Act Européen (Classification Haut Risque — Annexe III) :

- Les systèmes d'IA utilisés dans l'emploi et l'orientation relèvent de la catégorie **Haut Risque**.
- Exigences impératives : traçabilité des données, explicabilité, gouvernance des biais et **supervision humaine obligatoire** (*Human-In-The-Loop*).

### 2. Loi pour une République Numérique (Art. L311-3-1) :

- Droit pour l'utilisateur à l'information et à l'explicabilité individuelle des règles algorithmiques appliquées.

### 3. Responsabilité Juridique & Notion de "Perte de Chance" :

- Si un usager vulnérable est mal orienté (classé en retour rapide par erreur), il subit un préjudice (privation d'aides ou de formations). Devant le Tribunal Administratif, la **perte de chance** engage la responsabilité de l'administration.
- **Protection juridique par conception** : L'outil est strictement qualifié d'**aide à la décision consultative**. L'agent public valide et endosse souverainement la décision finale.

## 2. Audit & Ingénierie des Données

## Le Défi de la Donnée : "Small Data", Cardinalité & Qualité

- **Jeu de données** : 2 500 profils usagers historiques, 10 variables, présence de valeurs manquantes (âge, diplôme, allocataire, texte).
- **Problème technique (Malédiction de la dimensionnalité)** :
  - `code_insee_commune` : > 2 400 communes distinctes pour 2 500 lignes.
  - `code_rome_vise` : > 50 métiers distincts.
  - Entraîner sur ces données brutes conduirait à un sur-apprentissage (*overfitting*) immédiat.

### Décision Technique : Extraction de Macro-Tendances

Dérivation du **Département** (2 premiers caractères du code INSEE) et de la **Famille ROME** (1ère lettre).

**Limites assumées de l'échantillon (2 500 lignes)** : En agrégeant par département, on sacrifie la granularité du bassin d'emploi local (pôle dynamique vs zone rurale isolée), compromis nécessaire pour éviter la mémorisation par cœur.

## La Sélection des Variables : Éthique & Biais (AI Act)

- Biais historiques constatés (EDA) :
  - Âge : 29% des seniors (45-65 ans) en risque long vs 9% des 25-45 ans.
  - Nationalité hors UE : 38% en risque long vs 15% pour les ressortissants UE.
- Risque légal (Disparate Impact) : Risque de discrimination algorithmique sanctionnée par l'AI Act et la *Loi pour une République Numérique*.
- Transparence : Rédaction d'une **Datasheet for Datasets** (Gebru et al.) dans `data/DATASHEET.md`.

**Décision Stratégique (Privacy by Design — Scénario S2)** : Retrait de l'Âge et de la Nationalité pour forcer le modèle à chercher les causes objectives (freins textuels, secteur, parcours).

**Constat lucide (Échec du *Fairness through Blindness*)** : Les variables proxy (département, diplôme) réintroduisent un biais résiduel. D'où l'impératif du filet humain (HITL).

## Analyse du Texte (NLP) : Problématique et Possibilités

- **La Problématique** : La `synthese_entretien` est un champ libre, non structuré. C'est le prédicteur n°1 du jeu de données (mots-clés : *freins périphériques, perte de confiance, autonome*).
- **Le Défi** : Transformer des notes hétérogènes en représentations numériques exploitables en temps réel.
- **Les Possibilités techniques** :
  - i. *Bag of Words (Comptage brut)* : Bruit statistique, domination des mots vides.
  - ii. *Deep Learning (CamemBERT / Embeddings / LLM)* : Très lourd, approche "boîte noire", risque d'overfitting sur 2 500 textes courts, non aligné sur la sobriété numérique.
  - iii. *TF-IDF (Term Frequency - Inverse Document Frequency)* : Pondération de la rareté des termes.

## Notre Choix NLP : TF-IDF avec Stop Words Français

Nous avons retenu l'approche **TF-IDF filtrée** pour trois raisons déterminantes :

1. **Obligation Légale & Transparence (AI Act)** : Système 100% explicable. Chaque mot possède un poids direct traçable (ex: "barrière", "santé", "complexe").
2. **Robustesse sur Petit Volume** : Aucun risque d'explosion paramétrique contrairement aux réseaux de neurones. Espace vectoriel plafonné à 1 000 features avec filtrage `max_df=0.85` et stopwords français.
3. **Green IT & Temps Réel (Principe KISS)** : Inférence en moins de **0.1 ms sur simple CPU**, sans aucune dépendance à des infrastructures GPU coûteuses et énergivores.

## Le Pipeline Scikit-Learn End-to-End (Anti-Data Leakage)

Toute la chaîne est encapsulée dans un `Pipeline` Scikit-Learn sérialisé, assurant une **herméticité totale** et une utilisation immédiate en production :



- **Zéro Data Leakage** : Préparé et ajusté strictement après le `train_test_split` stratifié.
- **Entrées brutes acceptées** : L'API et les services aval injectent directement `code_insee_commune` et `code_rome_vise` sans prétraitement externe.

## 3. Modélisation, Scénarios & Explicabilité


## Le Défi du Déséquilibre : La Réalité des Données

- Répartition de la cible (3 classes) :
  - Classe 0 (Rapide < 6m) : 37%
  - Classe 1 (Moyen 6-12m) : 44%
  - Classe 2 (Risque > 12m) : 18% (*critique*)
- Le Piège de l'Accuracy : Un modèle naïf prédisant 0 ou 1 obtient 81% d'Accuracy en abandonnant 100% des personnes à risque !

### Boussole unique (F1-Score Macro) :

C'est la note moyenne obtenue sur les 3 classes en donnant le même poids à chacune : si l'IA oublie la classe minoritaire à risque, sa note globale s'effondre.

Répartition des profils (Déséquilibre)



## Asymétrie des Coûts : Deux Leviers pour Réduire les Erreurs Critiques

Classer un profil en risque (2) en retour rapide (0) est bien plus grave qu'une fausse alerte. Deux leviers :

### 1. En Amont : À l'Entraînement (Cost-Sensitive Learning)

- **Pondération automatique** — `class_weight='balanced'` (Retenu) :  
Chaque profil à risque pèse  $\sim 2,4\times$  plus lourd, forçant l'algorithme à ne pas l'ignorer.
- **Poids personnalisés** — *Custom Sample Weights* :  
Possibilité de sur-pénaliser davantage les erreurs sur les demandeurs vulnérables.

### 2. En Aval : À la Décision (Cost-Sensitive Thresholding)

- **Seuil d'alerte préventif abaissé** — *Decision Threshold Tuning* :  
Déclencher l'aide dès 25% de risque détecté, sans attendre une certitude absolue.
- **Seuil d'abstention (65%)** — *Rejection Threshold (HITL)* :  
En cas de doute, l'IA passe la main au conseiller humain (*Human-in-the-Loop*).

**Synthèse** : On combine une pondération à l'apprentissage et un filet d'alerte précoce à la décision pour protéger les usagers fragiles sans alourdir le modèle.

## Le Benchmark : Duel sous Validation Croisée Stratifiée

- **Méthodologie** : 5-Fold Stratified Cross-Validation sur `x_train` avec traçabilité complète sous **MLflow**.
- **Comparatif des familles** :

| Modèle                   | F1-Macro CV<br>(Moyenne) | Écart-<br>type | Atouts                                                            | Limites                                                            |
|--------------------------|--------------------------|----------------|-------------------------------------------------------------------|--------------------------------------------------------------------|
| Régression<br>Logistique | ~0.664                   | 0.016          | Baseline rapide, poids linéaires<br>directs                       | Moins apte aux interactions non-<br>linéaires                      |
| Random Forest            | ~0.660                   | <b>0.012</b>   | Très stable, robuste aux outliers                                 | Forêt volumineuse en RAM,<br>latence plus élevée                   |
| LightGBM                 | ~ <b>0.680</b>           | 0.014          | <b>Meilleure performance</b> ,<br>gestion native matrices creuses | Risque fort de sur-apprentissage<br>(overfitting) sur petit volume |

## Optimisation des Hyperparamètres (GridSearchCV + MLflow)

Duel final entre **Random Forest** et **LightGBM** avec régularisation ciblée pour contrer l'overfitting :

- **Hyperparamètres retenus (LightGBM vainqueur) :**
  - `n_estimators = 100` : Nombre d'arbres maîtrisé.
  - `learning_rate = 0.05` : Apprentissage doux pour une meilleure généralisation.
  - `num_leaves = 15` & `min_child_samples = 20` : Interdiction formelle de créer des branches pour un groupe d'utilisateurs trop restreint.
  - `class_weight = 'balanced'` : Protection active de la classe minoritaire.

**Gouvernance MLOps** : Tous les hyperparamètres, scores CV et artefacts ont été journalisés sous l'expérience `certif_ia_modelisation` dans MLflow.

# Analyse Comparée des 4 Scénarios (Cœur du Sujet)


| Scénario      | Périmètre                               | F1-Macro | FN (Classe 2) | Disparate Impact       | Conformité AI Act | Verdict                                                                                         |
|---------------|-----------------------------------------|----------|---------------|------------------------|-------------------|-------------------------------------------------------------------------------------------------|
| S1 (Complet)  | Tabulaire + Texte + Variables sensibles | 0.716    | 24            | 2.53 (Fort biais)      | ✗ Non conforme    | Rejeté prod                                                                                     |
| S2 (Éthique)  | S1 sans âge ni nationalité              | 0.627    | 33            | 1.41 (Proxy réduit)    | ✓ Conforme (PbD)  |  Retenu prod |
| S3 (NLP seul) | Synthèse entretien seule                | 0.637    | 32            | 1.62 (Biais verbatims) | ⚠ Trop fragile    | Rejeté prod                                                                                     |

## Explicabilité Locale et Globale (SHAP sur S2)

### L'audit TreeExplainer valide l'hybridation :

- **Explicabilité Globale (Population) :**
  - **Ancienneté d'inscription :** Ancre administrative n°1 (forte ancienneté  $\rightarrow$  pousse vers le risque long).
  - **Mots-clés NLP (TF-IDF) :** Les termes signalant des freins périphériques déclenchent l'alerte.
  - **Non-discrimination prouvée :** Zéro variable démographique sensible dans la décision.
- **Explicabilité Locale (UI Streamlit) :**  
Restitution unitaire au conseiller (force plot / waterfall) expliquant précisément chaque recommandation (RGPD Art. 22).

**Transparence totale (AI Act) :** Le modèle n'est plus une boîte noire : chaque prédiction est justifiable mot par mot.



## 4. Architecture Backend & Industrialisation

## De la Modélisation à la Production

Le passage de l'expérimentation vers un service industriel sécurisé :

1. **Sérialisation unifiée** : Export d'un artefact unique `pipeline_production.joblib` contenant la fonction d'extraction, les transformateurs et le LightGBM entraîné.
2. **Model Card Technique** : Fichier `pipeline_production.json` traçant les versions d'OS/Python, l'empreinte MD5 du dataset source ( `2605ca...` ), les hyperparamètres et la matrice de confusion.
3. **Suite de Tests Automatisée** : 6 tests unitaires et d'intégration validant le chargement du modèle, les formats d'inférence et le rejet des entrées invalides (Pytest).

## L'API FastAPI : Typage Strict & Validation Pydantic


### 4 routes RESTful asynchrones :

- GET /health : Diagnostic & disponibilité modèle.
- POST /predict : Inférence unitaire + probas + Fallback.
- POST /predict/batch : Traitement par lot pour le SI.
- POST /train : Réentraînement sécurisé (API Key).

**Robustesse** : Toute donnée non conforme (ex: ancienneté < 0) est rejetée avec un code 422 Unprocessable Entity .

```
# Validation Pydantic automatique
class UsagerInput(BaseModel):
    anciennete_poste_ans: float = Field(..., ge=0, le=50)
    niveau_diplome: str
    code_insee_commune: str = Field(..., min_length=5, max_length=5)
    code_rome_vise: str = Field(..., min_length=5, max_length=5)
    est_allocataire: int = Field(..., ge=0, le=1)
    synthese_entretien: str = Field(default="")
```

## L'Interface Conseiller (Streamlit) & Intégration SI



### Hébergement Souverain (SecNumCloud) :

Cloud souverain (OVHcloud, Outscale) pour concilier élasticité, résilience et conformité aux données publiques de l'emploi (vs On-Premise rigide).

### IHM Conseiller Ergonomique :

Code couleur métier (Vert, Orange, Rouge), jauge de confiance et alerte d'escalade humaine immédiate si la confiance est < 65%.

## Démarche CI/CD & Déploiement Reproductible (GitHub Actions)

Le projet intègre un cycle d'ingénierie logicielle continu automatisé sur GitHub Actions :

Pipeline Automatisé sur `master` :

1. **Contrôle Qualité & Linting** : Analyse statique du code Python via `flake8` / `black`.
2. **Tests Automatisés (Pytest)** :
  - `test_api.py` : Santé, validation Pydantic (422), batch et réponses unitaires.
  - `test_pipeline.py` : Présence modèle, prédiction probas = 1.0 sur données brutes.
3. **Construction Conteneur Docker** :
  - Multi-stage build Python 3.12-slim (< 300 Mo).
  - Sécurité : exécution non-root, sans cache de build.
4. **Orchestration** : `docker-compose.yml` multiservices (FastAPI, Streamlit, Prometheus, Grafana).

Garanties pour le Jury :


- ✓ **100% Reproductible** : Un clone + `docker compose up` suffit pour monter le SI complet.
- ✓ **Zéro Régression** : La CI bloque toute mise en production si un test ou un schéma échoue.
- ✓ **Conformité MLOps** : Cycle de vie tracé du code au conteneur.

## 5. Supervision MLOps & Amélioration Continue

## Le Monitoring en Temps Réel (Prometheus & Grafana)

Architecture conteneurisée via **Docker-Compose** intégrant nativement la métrologie :

- **Métriques Système** : Latence p95 ( $< 100$  ms) et taux d'erreurs HTTP.
- **Métriques Métier** :
  - Volume de prédictions par classe (détection d'anomalies de répartition).
  - Histogramme des scores de certitude.
  - **Taux d'escalade (Fallback rate)**.
- **Alerting MLOps** : Dérive relative  $> 20\%$  du taux d'abstention sur 4 semaines.



## Le Fallback : Seuil de Rejet (65%) & Biais d'Automatisation

- **Le Risque UX** : Face à un flux tendu, un conseiller peut subir le *biais d'automatisation* (suivre aveuglément l'avis de la machine).

### Pourquoi fixer le seuil à 65% ?

- **Hasard pur à 33% (3 classes)** : À 65% de certitude, l'IA accorde deux fois plus de poids à la classe prédite qu'aux deux autres réunies.
- **Filet de sécurité du modèle S2** : Le modèle éthique ayant un Recall de 63% sur le risque, ce seuil conservateur évite de trancher sur les cas limites.
- **Consigne ergonomique** : Possibilité de masquer la jauge brute pour obliger l'agent à exercer son esprit critique.

### Logique du Filet de Sécurité (API)

- Confiance  $\geq 65\%$  : Feu Vert

L'IA affiche la recommandation d'orientation au conseiller.

- Confiance  $< 65\%$  : Abstention (Fallback)

L'API renvoie `fallback: true`. L'IHM invite le conseiller à décider en autonomie (*Human-In-The-Loop*).

## Alerte Dérive (> 20%) : Le Signal d'Alarme Précoce

La vérité terrain (retour à l'emploi effectif) n'est connue que 6 à 12 mois plus tard. **Comment détecter une panne du modèle dès aujourd'hui ?**

### Pourquoi une alerte sur une hausse relative de > 20% ?

- Taux nominal baseline : ~38-40% des dossiers sont sous 65%.
- Filtrage du bruit statistique : Une variation de  $\pm 10\%$  est une fluctuation normale (saisonnalité, congés).
- Seuil critique (+20% relatif) : Si le taux de rejet dépasse 48% sur 4 semaines glissantes, c'est une dérive structurelle :
  - *Data Drift sémantique* : vocabulaire des conseillers qui a changé.
  - *Choc économique* : afflux de profils inédits post-crise sectorielle.

### Plan d'Action MLOps (Playbook) :

1. **Contrôle PSI** : Vérifier quelles variables d'entrée ont dérivé.
2. **Recalibration** : Ajuster les probabilités (Platt/Isotonique) sans réentraîner si seule la confiance s'est tassée.
3. **Réentraînement déclenché** : Appel de l'endpoint `POST /train` si le drift persiste.


## Cycle de Vie : Boucle de Rétroaction & Dérive (Drift)

- **Le Piège de la Prophétie Auto-Réalisatrice :**

L'IA classe un usager en *Risque long* → L'agence lui offre un suivi renforcé → Il retrouve un emploi en 4 mois.

*Le piège lors du réentraînement :* Le modèle conclut à tort qu'il s'agissait d'un profil "rapide" et le privera d'aide la fois suivante !

- **Solution par conception :** Enregistrement obligatoire de la variable `a_beneficie_aide_renforcee` pour neutraliser ce biais.



- **Surveillance du Data Drift :** Calcul mensuel du **PSI (Population Stability Index)** sur les données entrantes. Si  $PSI > 0.20$  sur les variables clés (métier, vocabulaire), déclenchement d'un réentraînement supervisé.

## 6. Bilan Économique, Perspectives & Conclusion

## Comparatif Économique & ROI (FinOps & Métier)

### 1. Coût d'Inférence & Empreinte Numérique (FinOps) :

- LightGBM + TF-IDF : Consommation RAM < 200 Mo, latence < 1 ms sur simple CPU.
- Économie de 80% par rapport à un cluster GPU dédié à des LLMs ou Transformers.

### 2. L'Économie de l'Erreur :

- **Faux Positif (Alarme inutile)** : Coût modéré = un entretien approfondi de 30 min (~25€ de temps conseiller).
- **Faux Négatif (Risque raté)** : Coût sociétal majeur = 12 à 24 mois d'indemnisation chômage, perte de cotisations et rupture sociale (> 15 000€).
- *Le modèle maximise le ROI social en tolérant des fausses alarmes pour éradiquer les abandons.*

## Perspectives de Passage à l'Échelle (Scale-up)

| Axe                   | Échelle MVP (2 500 profils)                   | Échelle Nationale (1 000 000 profils)                                                   |
|-----------------------|-----------------------------------------------|-----------------------------------------------------------------------------------------|
| Données Géographiques | Agrégation par département (anti-overfitting) | Exploitation du code commune INSEE brut (bassins d'emploi fins)                         |
| Analyse NLP           | TF-IDF avec Stop Words (léger, explicable)    | Modèles d'embeddings CamemBERT fine-tunés avec surcouche LIME/SHAP                      |
| Pipeline MLOps        | SQLite MLflow local                           | Feature Store centralisé (Feast), Registry MLflow distant & Model Monitoring en continu |

## Conclusion

- ✅ **Système de bout en bout opérationnel** : Du cadrage métier et audit des données jusqu'à l'API FastAPI, l'UI Streamlit, Docker et la CI/CD GitHub Actions.
- ✅ **Conformité stricte AI Act** : Modèle S2 éthique, explicabilité SHAP prouvée, politique d'abstention sous 65% et supervision humaine garantie.
- ✅ **Pragmatisme d'ingénierie** : Solution sobre (Green IT), réactive ( $< 1$  ms) et alignée sur la réalité du service public de l'emploi.

**Merci de votre attention.**